파이썬 라이브러리를 활용한 데이터 분석

9장 그래프와 시각화

9장 그래프와 시각화

Matplotlib

Matplotlib 개요

- **2D 그래프를 위한 데스크탑 패키지**
  - 파이썬에서 자료를 차트(chart)나 플롯(plot)으로 시각화(visualaization)하는 패키지
  - 정형화된 차트나 플롯 이외에도 저수준 API를 사용한 다양한 시각화 기능을 제공
    - **라인 플롯(line plot)**
    - **스캐터 플롯(scatter plot)**
    - **컨투어 플롯(contour plot)**
    - **서피스 플롯(surface plot)**
    - **바 차트(bar chart)**
    - **히스토그램(histogram)**
    - **박스 플롯(box plot)**
  - 2002년 존 헌터가 시작
  - Matplotlib 갤러리 웹사이트
    - **http://matplotlib.org/gallery.html**

주피터 노트북 매직 명령어

- **%matplotlib inline**
  - 그림을 셀 아래에 결과로 삽입
  - 이제는 필요 없음
- **%matplotlib notebook**
  - 대화형 시각화 도구

```
In [7]: %matplotlib notebook
```

A Brief matplotlib API Primer

```
In [2]: import matplotlib.pyplot as plt
```

```
In [8]: import numpy as np
        data = np.arange(10)
        data
        plt.plot(data)
```

Figure 1

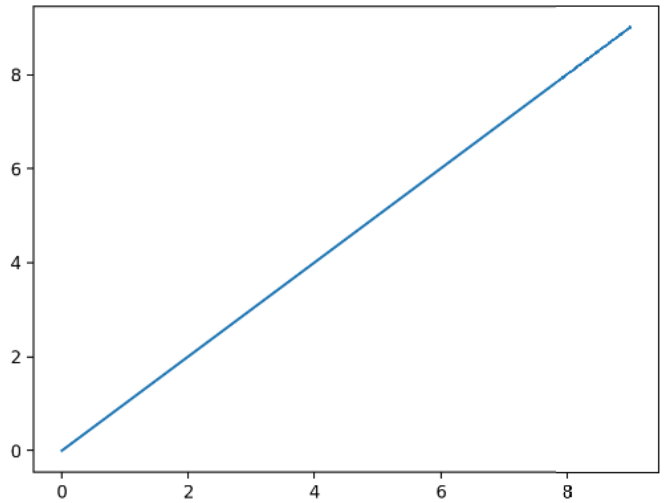


```
Out[8]: [<matplotlib.lines.Line2D at 0x25e9bc1c5c8>]
```

다음의 효과
%matplotlib notebook

API

- **plot()**
  - 가장 간단한 플롯은 선을 그리는 라인 플롯(line plot)
  - 라인 플롯은 데이터가 시간, 순서 등에 따라 어떻게 변화하는지 보여주기 위해 사용
    - http://matplotlib.org/api/pyplot_api.html#Matplotlib.pyplot.plot

한글 지원

- **지원 폰트 확인 후**
  - 지정

In [10]:
```
import matplotlib as mpl
sorted([f.name for f in mpl.font_manager.fontManager.ttflist])
```

```
 'Arial',
 'Arial',
 'Arial',
 'Arial',
 'Arial',
 'Arial',
 'Arial',
 'Arial',
 'Arial Rounded MT Bold',
 'Arvo',
 'Arvo',
 'Arvo',
 'Arvo',
 'Bahnschrift',
 'Baskerville Old Face',
 'Batang',
 'Bauhaus 93',
 'Bell MT',
 'Bell MT',
 'Bell MT',
```

In [11]:
```
import matplotlib as mpl

# 폰트 설정
#mpl.rc('font', family='NanumGothic')
mpl.rc('font', family='Malgun Gothic')
# 유니코드에서  음수 부호설정
mpl.rc('axes', unicode_minus=False)
```

figure와 subplot

- **figure 개요**
  - 그려지는 그래프가 figure 객체 내에 존재, 그림을 그리는 종이라고 이해
  - figsize=(10, 6)
    - **그림 크기: figsize 인수로 설정(크기와 비율을 지정)**
  - fig = plt.figure()
    - **figure 생성**
    - **figure 명령을 사용하여 그 반환 값으로 figure 객체를 얻음**
      - **일반적인 plot 명령 등을 실행하면 자동으로 Figure를 생성해 주기 때문에 일반적으로는 figure 명령을 잘 사용하지 않음**
    - **figure 명령을 명시적으로 사용하는 경우**
      - **여러 개의 윈도우를 동시에 띄워야 하거나(line plot이 아닌 경우)**
      - **Jupyter 노트북 등에서(line plot의 경우) 그림의 크기를 설정할 경우**
- **show()**
  - 시각화 명령을 실제로 차트로 렌더링(rendering)하고 마우스 움직임 등의 이벤트를 기다리라는 지시
  - 주피터 노트북에서는 셀 단위로 플롯 명령을 자동 렌더링 해주므로 show 명령이 필요 없음
  - 일반 파이썬 인터프리터로 가동되는 경우를 대비하여 항상 마지막에 실행

그림 구조

- **figure는 그림이 그려지는 캔버스나 종이**
  - Axes는 하나의 플롯, 그리고 Axis는 가로축이나 세로축 등의 축

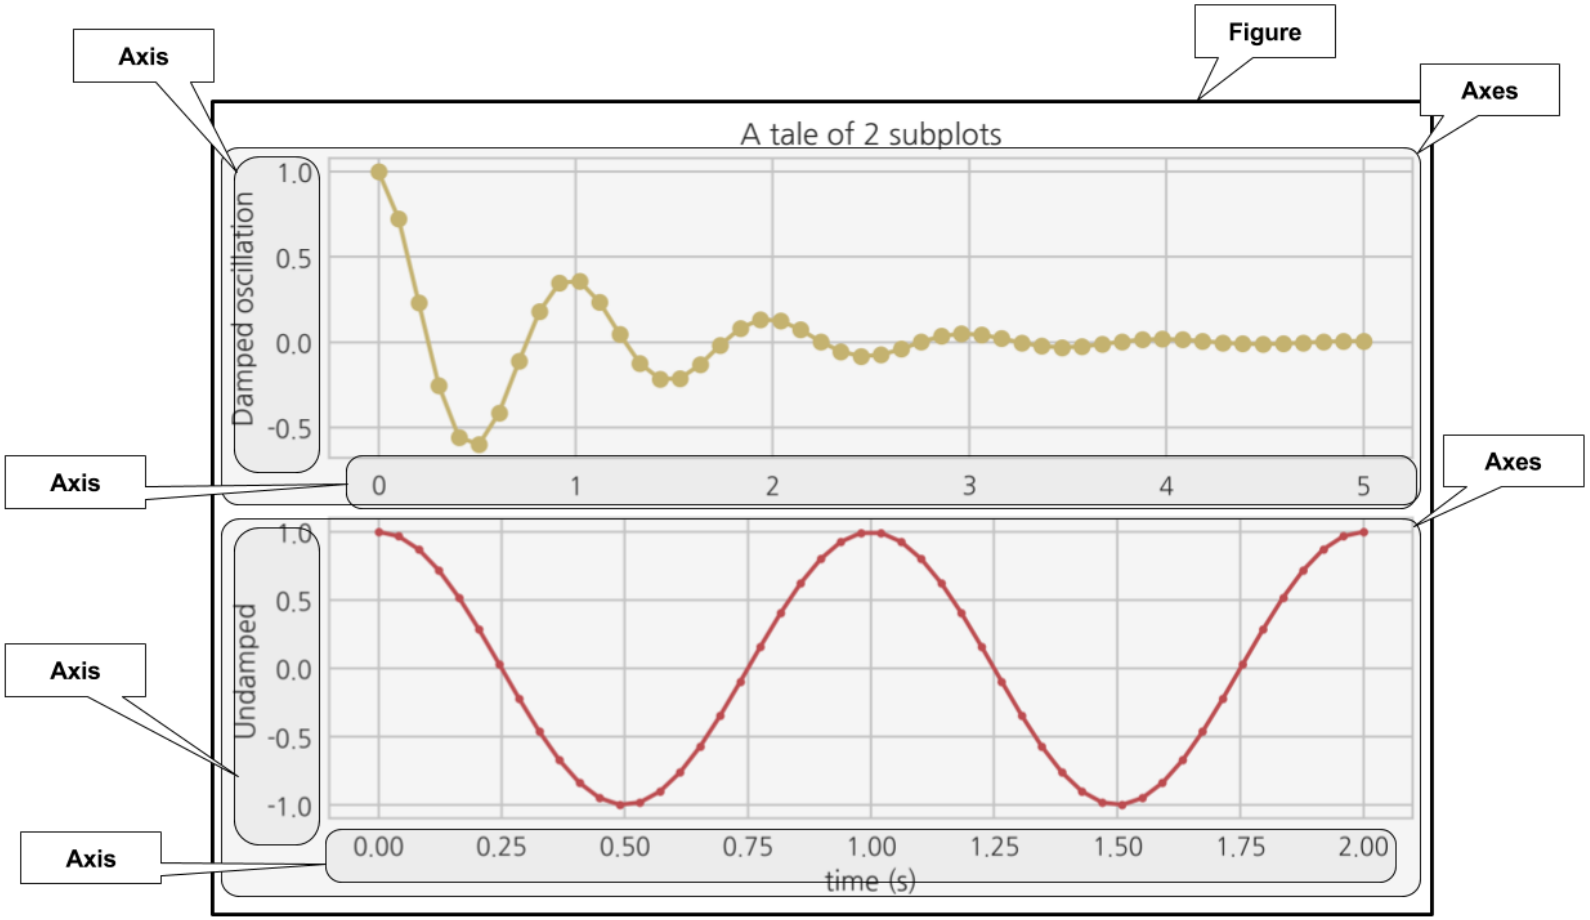

Subplot 개요

- **그리드(grid) 형태의 Axes 객체들을 생성**
  - figure 안에 있는 각각의 플롯은 Axes 라고 불리는 객체
    - **figure 내부에 행렬(matrix) 형태의 여러 그림이 있으며 이를 Axes라 함**
- **Axes: 내부의 subplot**
  - ax1 = fig.add_subplot(2, 2, 1)
    - **크기 2 x 2**
    - **4개의 그림 중 1번 그림**
  - ax2 = fig.add_subplot(2, 2, 2)
  - ax3 = fig.add_subplot(2, 2, 3)

```
In [15]: fig = plt.figure(figsize=(7, 5))
         #ax1 = fig.add_subplot(2, 2, 1)
         ax2 = fig.add_subplot(2, 2, 2)
         ax3 = fig.add_subplot(2, 2, 3)
```

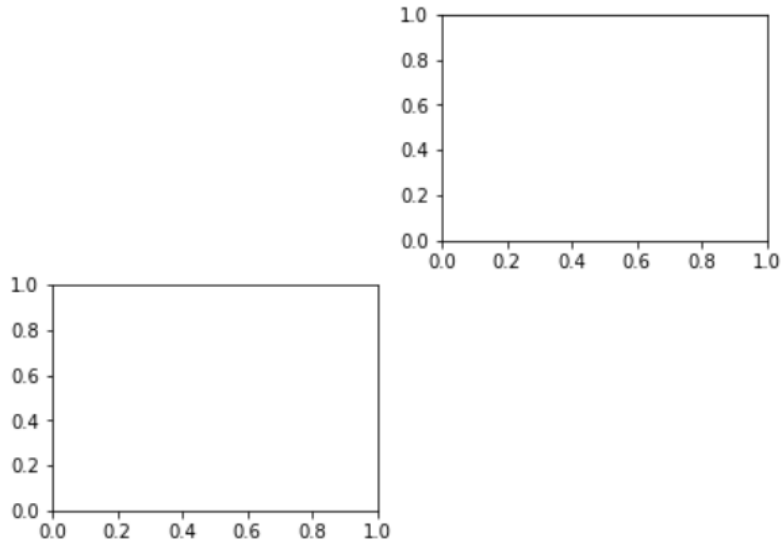

여러 그림 그리기

- 가장 최근의 figure와 그 서브플롯에 그림

```
In [19]: fig = plt.figure(figsize=(10, 8))
         #ax1 = fig.add_subplot(2, 2, 1)
         ax2 = fig.add_subplot(2, 2, 2)
         plt.plot(np.random.randn(50).cumsum(), 'k--')
         ax3 = fig.add_subplot(2, 2, 3)
```

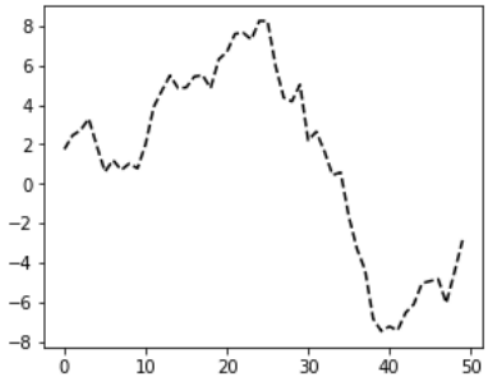

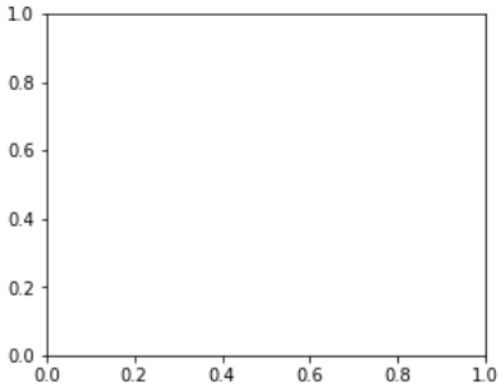

옵션 'k--'와 서브플롯 객체

- **black, 점선**
  - 색상
  - 선 스타일
    - **실선(solid), 대시선(dashed)**
    - **점선(dotted), 대시-점선(dash-dot)**
  - 마커(marker)
    - **데이터 위치를 나타내는 기호**
- **문자열 형태**
  - fmt = '[marker][line][color]' 또는 [color][marker][line]
    - **파악만 되면 순서는 상관 없음**
    - **'b'**
      - **# blue markers with default shape**
    - **'or'**
      - **# red circles**
    - **'-g'**
      - **# green solid line**
    - **'--'**
      - **# dashed line with default color**
    - **'^k:'**
      - **# black triangle_up markers connected by a dotted line**

문자열	약자
blue	b
green	g
red	r
cyan	c
magenta	m
yellow	y
black	k
white	w

선 스타일 문자열	의미
-	solid line style
--	dashed line style
-.	dash-dot line style
:	dotted line style

마커의 다양한 종류

- **마커**
  - 특정 지점의 실제 데이터를 돋보이게 그리기

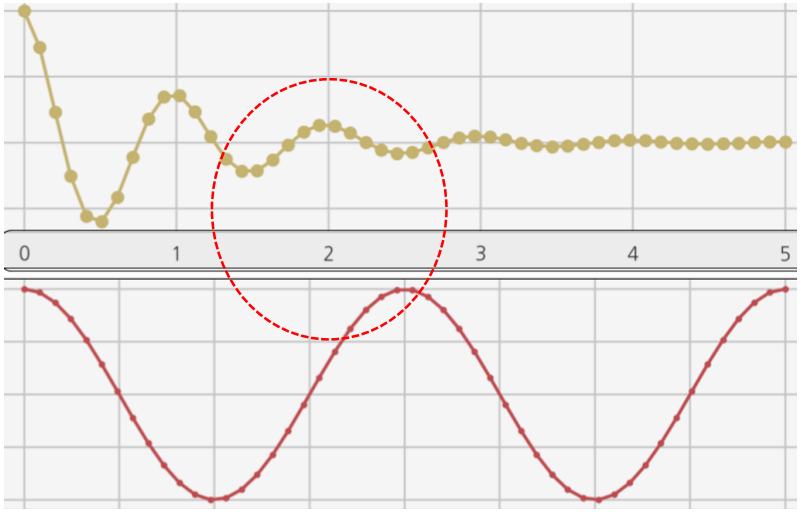

마커 문자열	의미
.	point marker
,	pixel marker
o	circle marker
v	triangle_down marker
^	triangle_up marker
<	triangle_left marker
>	triangle_right marker
1	tri_down marker
2	tri_up marker
3	tri_left marker
4	tri_right marker
s	square marker
p	pentagon marker
*	star marker
h	hexagon1 marker
H	hexagon2 marker
+	plus marker
x	x marker
D	diamond marker
d	thin_diamond marker

plt.subplot

- **그리드(grid) 형태의 Axes 객체들을 생성**
  - figure 안에 있는 각각의 플롯은 Axes 라고 불리는 객체
    - **figure 내부에 행렬(matrix) 형태의 여러 그림이 있으며 이를 Axes라 함**

- **ax1 = plt.subplot(2, 1, 1)**
  - ax1 = plt.subplot('211') 로도 가능
  - subplot(m, n, number)
  - 세 개의 인수
    - **m, n**
      - **전체 그리드 행렬의 모양을 지시하는 두 숫자**
    - **number**
      - **인수가 네 개 중 어느 것인지를 의미하는 숫자**
      - **첫번째 플롯을 가리키는 숫자가 0이 아니라 1임에 주의**

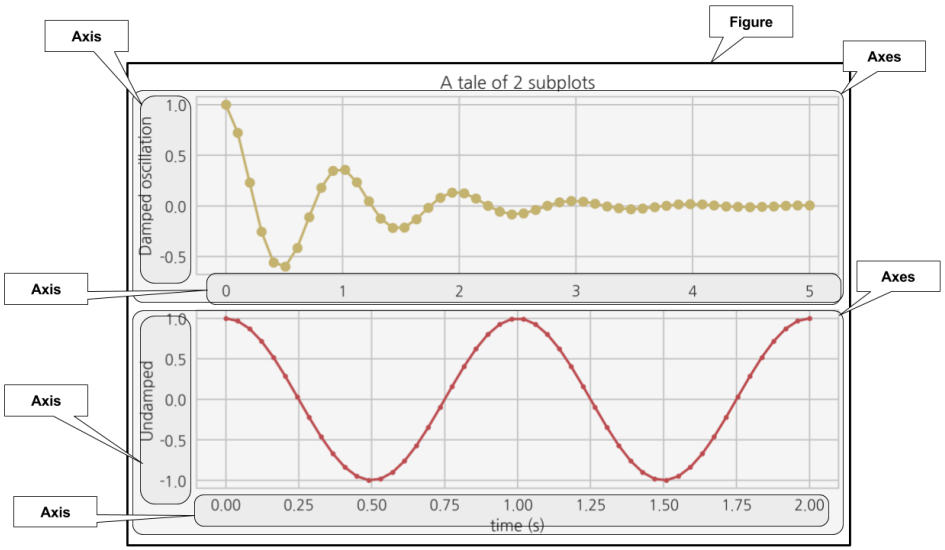

서브플롯 예

In [45]:
```
ax1 = plt.subplot(2, 1, 1)
plt.plot(np.random.randint(1, 10, 10), 'yo-')
plt.title('A tale of 2 subplots')
plt.ylabel('Damped oscillation')
print(ax1)

#ax2 = plt.subplot(2, 1, 2)
ax2 = plt.subplot(2, 1, 2)
plt.plot(np.arange(10), np.arange(10)*2, 'r.-')
plt.xlabel('time (s)')
plt.ylabel('Undamped')
print(ax2)

plt.tight_layout()
plt.show()
```

```
AxesSubplot(0.125,0.536818;0.775x0.343182)
AxesSubplot(0.125,0.125;0.775x0.343182)
```

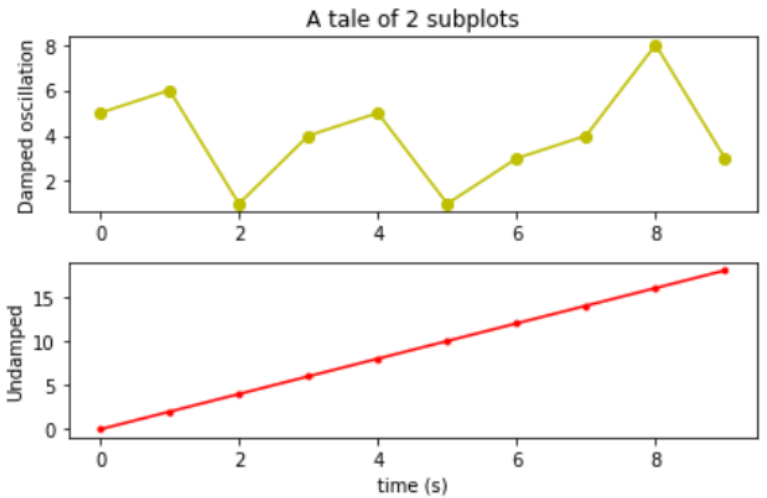

plt.subplots(m, n)

- 메소드
  - matplotlib.pyplot.subplots(nrows=1, ncols=1, sharex=False, sharey=False, squeeze=True, subplot_kw=None, gridspec_kw=None, **fig_kw)
  - 특정한 배치에 맞추어 여러 개의 서브플롯을 포함하는 figure를 생성
    - **인자 sharex=True, sharey=True**
      - **각 축의 인자를 하나로 공유**

Table 9-1. pyplot.subplots options

Argument	Description
`nrows`	Number of rows of subplots
`ncols`	Number of columns of subplots
`sharex`	All subplots should use the same x-axis ticks (adjusting the `xlim` will affect all subplots)
`sharey`	All subplots should use the same y-axis ticks (adjusting the `ylim` will affect all subplots)
`subplot_kw`	Dict of keywords passed to `add_subplot` call used to create each subplot
`**fig_kw`	Additional keywords to `subplots` are used when creating the figure, such as `plt.subplots(2, 2, figsize=(8, 6))`

서브플롯 예

In [47]:
```
fig, axes = plt.subplots(2, 2)

np.random.seed(0)
axes[0, 0].plot(np.random.rand(5))
axes[0, 0].set_title("axes 1")
axes[0, 1].plot(np.random.rand(5))
axes[0, 1].set_title("axes 2")
axes[1, 0].plot(np.random.rand(5))
axes[1, 0].set_title("axes 3")
axes[1, 1].plot(np.random.rand(5))
axes[1, 1].set_title("axes 4")

plt.tight_layout()
plt.show()
```

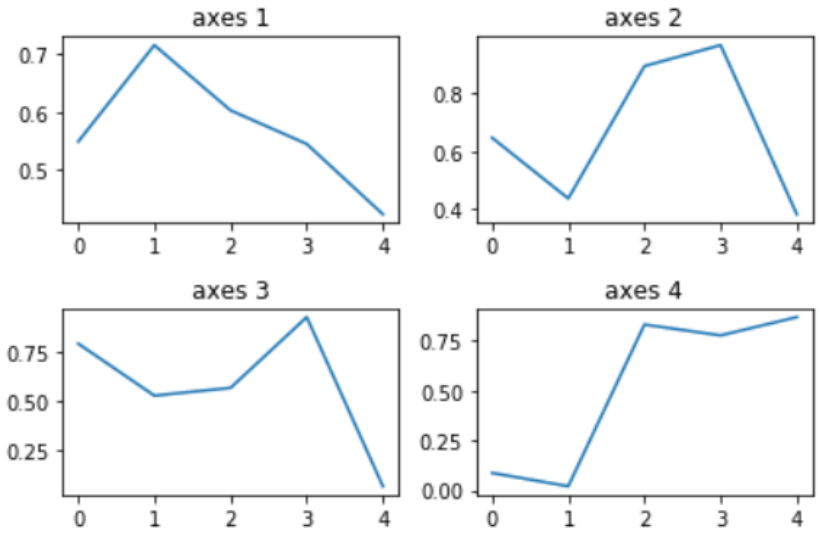

서브 플롯 간의 간격 조절하기

- **plt.subplots_adjust(wspace=0, hspace=.3)**
  - 서블플롯 간의 간격을 설정
    - **비율로 명시**
      - **.3은 30%의 공간 비우기**

```
In [61]: fig, axes = plt.subplots(2, 2, sharex=True, sharey=True, figsize=(8, 6))
for i in range(2):
    for j in range(2):
        axes[i, j].hist(np.random.randn(500), bins=50, color='k', alpha=0.5)
plt.subplots_adjust(wspace=0, hspace=.05)
#plt.subplots_adjust(wspace=None, hspace=None) #적정한 공간 비우기
```

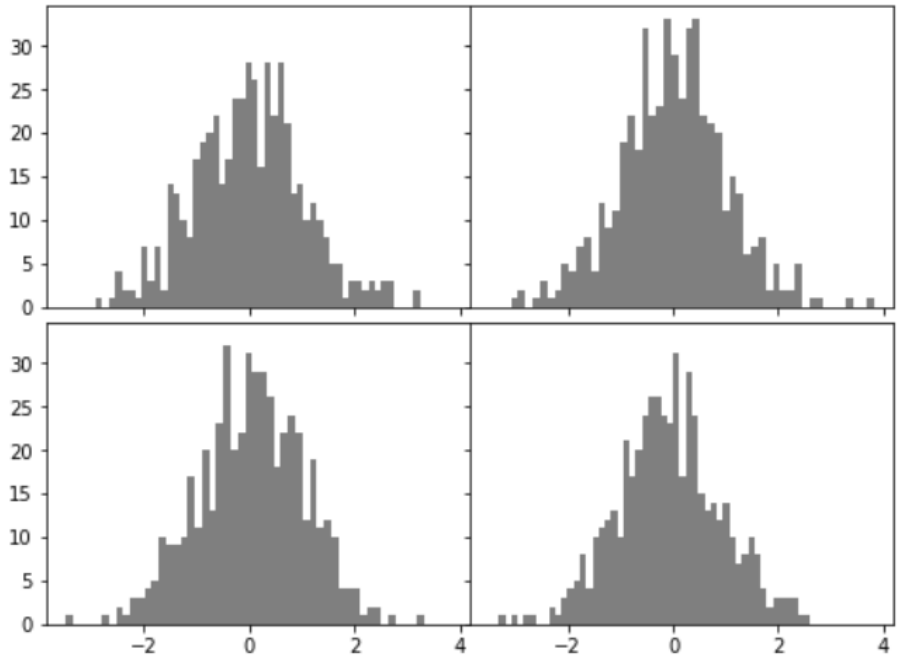

색상 마커 선 스타일

- **ax.plot(x, y, 'g--')**
  - ax.plot(x, y, linestyle='--', color='g')

```
In [66]: plt.plot(np.random.randn(30).cumsum(), color='b', linestyle='dashed', marker='o')
Out[66]: [<matplotlib.lines.Line2D at 0x23c0c615608>]
```

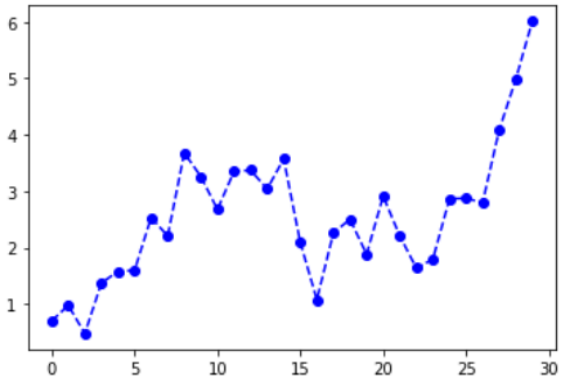

문자열	약자
blue	b
green	g
red	r
cyan	c
magenta	m
yellow	y
black	k
white	w

```
In [68]: plt.plot(np.random.randn(30).cumsum(), 'ro-.')
Out[68]: [<matplotlib.lines.Line2D at 0x23c0c541d48>]
```

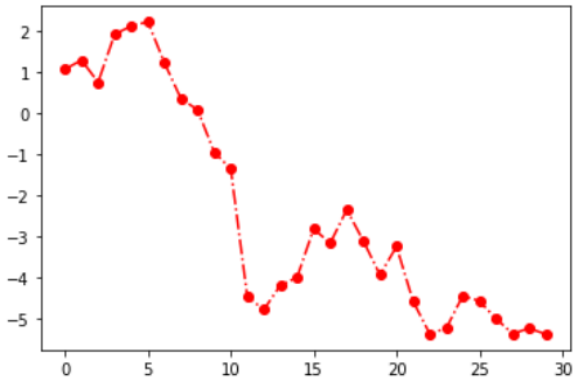

선 스타일 문자열	의미
-	solid line style
--	dashed line style
-.	dash-dot line style
:	dotted line style

옵션 drawstyle

- **일정한 간격으로 지정된 지점을 연결**
  - drawstyle or ds: {'default', 'steps', 'steps-pre', 'steps-mid', 'steps-post'}
    - **default: 'default'**

```
In [77]: plt.figure(figsize=(8, 6))
         data = np.random.randn(30).cumsum()
         plt.plot(data, 'c--', label='Default')
         plt.plot(data, '>b-', drawstyle='steps-post', label='steps-post')
         plt.legend(loc='best')

Out[77]: <matplotlib.legend.Legend at 0x23c11063b48>
```

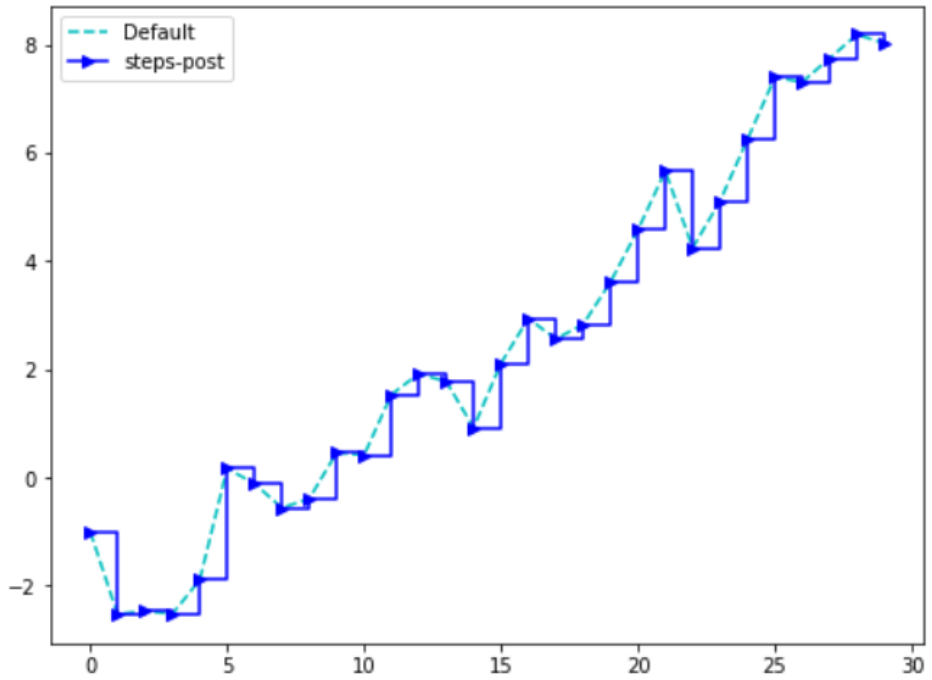

그래프를 꾸미는 방법 2 가지(1)

- **방법 1**
  - pyplot()으로 순차적으로
    - **ax = fig.add_subplot(1, 1, 1)**
  - 제공 API 사용
    - **set_title()**
    - **set_xlabel()**

```
In [89]: fig = plt.figure()
         ax = fig.add_subplot(1, 1, 1)
         ticks = ax.set_xticks([0, 250, 500, 750, 1000])
         labels = ax.set_xticklabels(['one', 'two', 'three', 'four', 'five'],
                                     rotation=30, fontsize='small')
         ax.plot(np.random.randn(1000).cumsum())

         ax.set_title('My first matplotlib plot')
         ax.set_xlabel('Stages')
Out[89]: Text(0.5, 0, 'Stages')
```

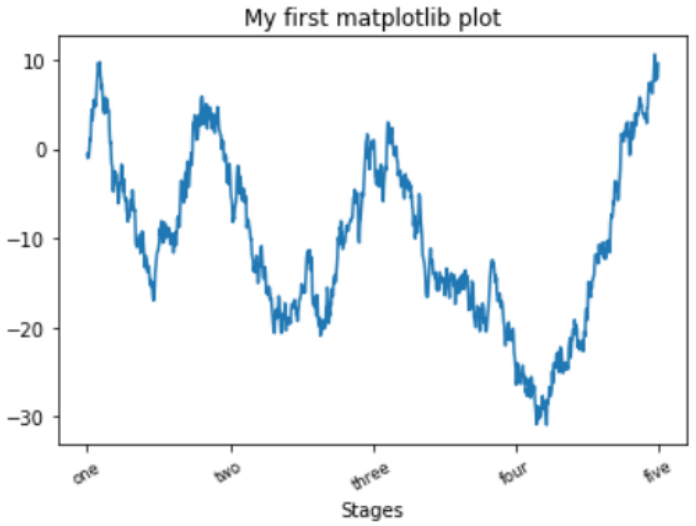

그래프를 꾸미는 방법 2 가지(2)

- **방법 2**
  - 클래스 axes의 메소드 set()
    - **여러 속성을 사전으로 지정**

```
In [101]: fig = plt.figure()
          ax = fig.add_subplot(1, 1, 1)
          ticks = ax.set_xticks([0, 250, 500, 750, 1000])
          labels = ax.set_xticklabels(['one', 'two', 'three', 'four', 'five'],
                                      rotation=30, fontsize='small')
          ax.plot(np.random.randn(1000).cumsum())

          #ax.set_title('멧플롯리브 그림')
          #ax.set_xlabel('단계')
          props = { 'title': 'My first matplotlib plot', 'xlabel': 'Stages' }
          ax.set(**props)

Out[101]: [Text(0.5, 0, 'Stages'), Text(0.5, 1.0, 'My first matplotlib plot')]
```

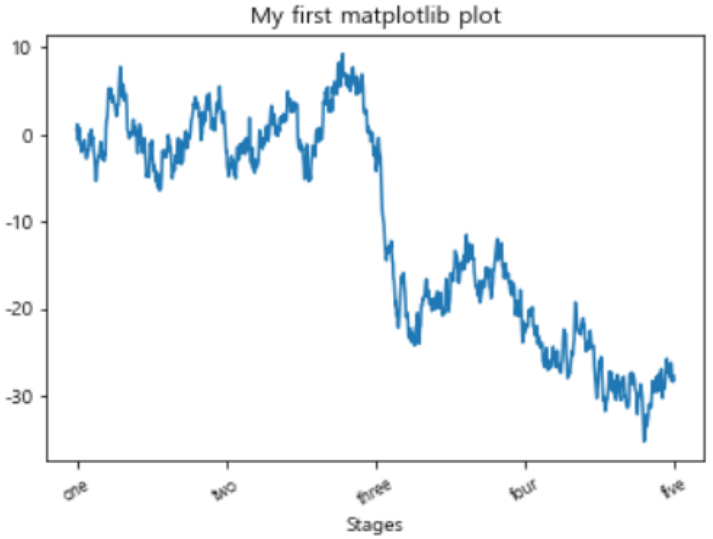

범례 추가하기

- **legend()**
  - 위치 지정
    - **loc='best'**

Location String	Location Code
'best'	0
'upper right'	1
'upper left'	2
'lower left'	3
'lower right'	4
'right'	5
'center left'	6
'center right'	7
'lower center'	8
'upper center'	9
'center'	10

Adding legends

In [109]:
```
from numpy.random import randn
fig = plt.figure();
ax = fig.add_subplot(1, 1, 1)
ax.plot(randn(1000).cumsum(), 'r', label='one')
ax.plot(randn(1000).cumsum(), 'g--', label='two')
ax.plot(randn(1000).cumsum(), 'b.', label='three')

ax.legend(loc='best')
```

Out[109]: <matplotlib.legend.Legend at 0x23c125c9bc8>

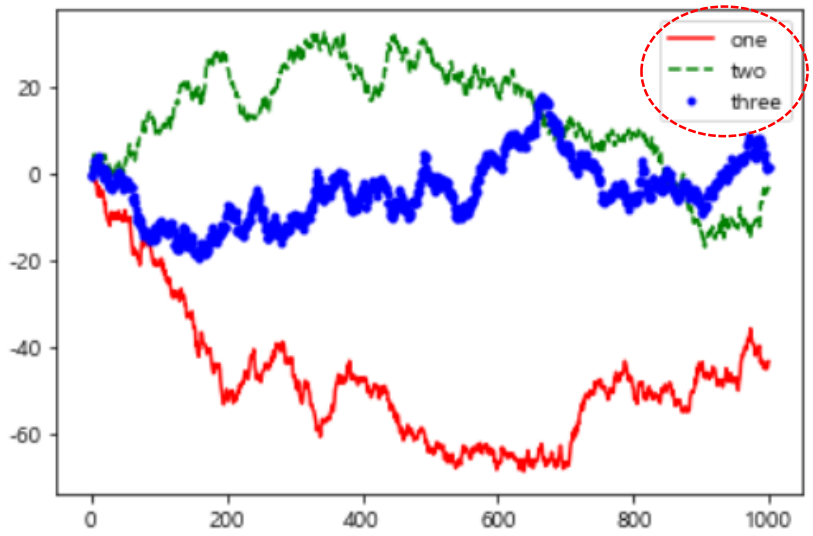

주석 달기

- **matplotlib.pyplot.annotate(s, xy, *args, **kwargs)**
  - ax.annotate(label, xy=(date, spx.asof(date) + 75),
  - xytext=(date, spx.asof(date) + 225),
  - arrowprops=dict(facecolor='blue', headwidth=4, width=2,
  - headlength=4),
  - horizontalalignment='left', verticalalignment='top')
    - **xy: 주석의 위치**
    - **xytext: 주석 글자의 위치**
    - **화살표는 xytext에서 xy로 그려짐**

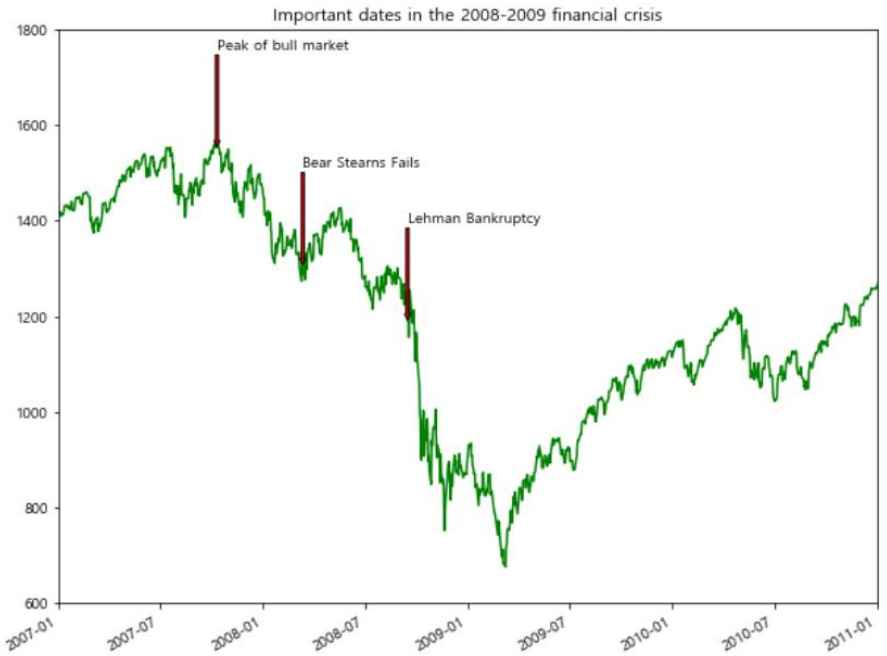

주석 화살표 그리기

- **옵션 arrowprops**

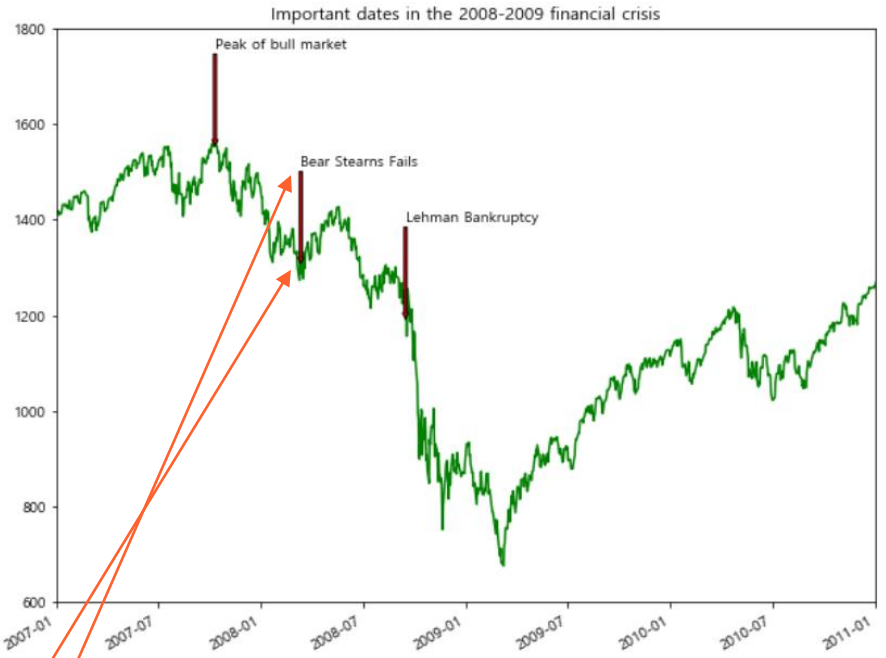

In [131]:
```
import pandas as pd
from datetime import datetime

fig = plt.figure(figsize=(10, 8))
ax = fig.add_subplot(1, 1, 1)

data = pd.read_csv('examples/spx.csv', index_col=0, parse_dates=True)
spx = data['SPX']

spx.plot(ax=ax, style='g-')

crisis_data = [
    (datetime(2007, 10, 11), 'Peak of bull market'),
    (datetime(2008, 3, 12), 'Bear Stearns Fails'),
    (datetime(2008, 9, 15), 'Lehman Bankruptcy')
]

for date, label in crisis_data:
    ax.annotate(label, xy=(date, spx.asof(date)),
                xytext=(date, spx.asof(date) + 225),
                arrowprops=dict(facecolor='red', headwidth=4, width=2,
                                headlength=4),
                horizontalalignment='left', verticalalignment='top')

# Zoom in on 2007-2010
ax.set_xlim(['1/1/2007', '1/1/2011'])
ax.set_ylim([600, 1800])

ax.set_title('Important dates in the 2008-2009 financial crisis')
```

판다스 데이터 그리기

- 시리즈
- 데이터프레임

In [150]:
```
import pandas as pd
s = pd.Series(np.random.randn(10).cumsum(), index=np.arange(0, 100, 10))
s.plot()
```

Out[150]:
```
<matplotlib.axes._subplots.AxesSubplot at 0x23c18844908>
```

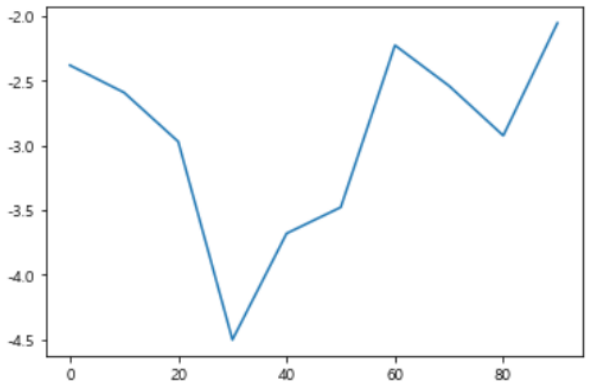

In [151]:
```
df = pd.DataFrame(np.random.randn(10, 4).cumsum(0),
                  columns=['A', 'B', 'C', 'D'],
                  index=np.arange(0, 100, 10))
df.plot()
```

Out[151]:
```
<matplotlib.axes._subplots.AxesSubplot at 0x23c188aa988>
```

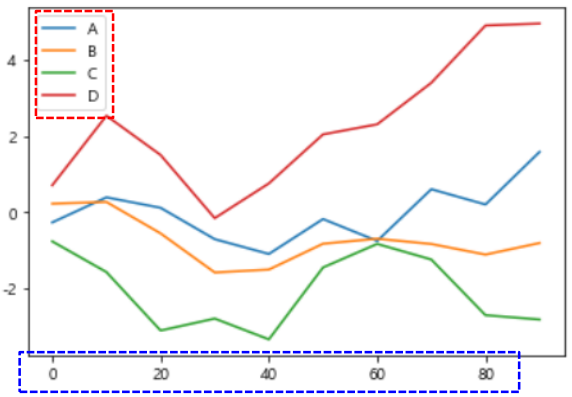

막대 그래프

- **메소드 bar(), barh()**
  - 색상의 투명도 옵션 alpha=

```
In [153]: fig, axes = plt.subplots(2, 1)
          data = pd.Series(np.random.rand(16), index=list('abcdefghijklmnop'))
          data.plot.bar(ax=axes[0], color='k', alpha=0.7)
          data.plot.barh(ax=axes[1], color='b', alpha=0.7)

Out[153]: <matplotlib.axes._subplots.AxesSubplot at 0x23c18a95b88>
```

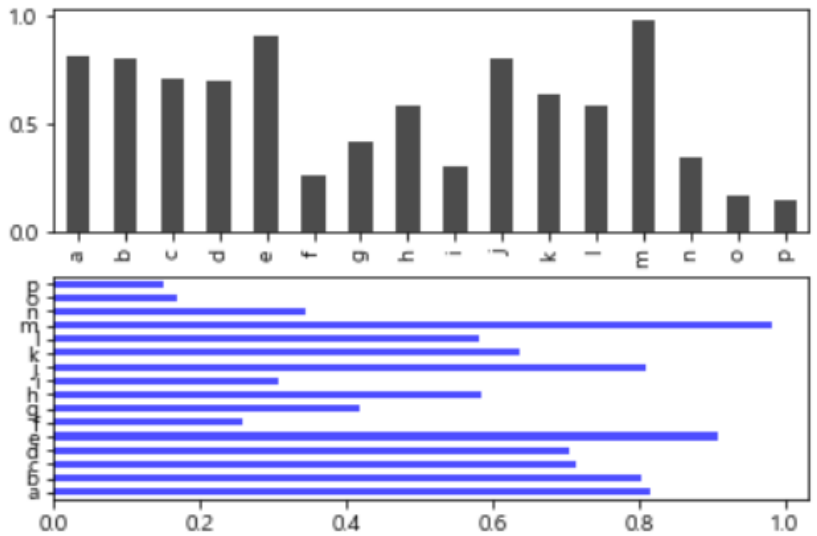

데이터프레임

- **막대 그래프**
  - index 이름이 범례 이름

```
In [155]: df = pd.DataFrame(np.random.rand(6, 4),
                            index=['one', 'two', 'three', 'four', 'five', 'six'],
                            columns=pd.Index(['A', 'B', 'C', 'D'], name='Genus'))
          df
```

Out[155]:

Genus	A	B	C	D
one	0.664737	0.872716	0.167458	0.114329
two	0.789941	0.569340	0.135387	0.029364
three	0.790764	0.285031	0.714794	0.790372
four	0.481273	0.356014	0.622913	0.641138
five	0.951389	0.405259	0.632018	0.724206
six	0.632867	0.259472	0.012550	0.240667

```
In [160]: df.plot.bar(ylim=[0, 1.2])
```

```
Out[160]: <matplotlib.axes._subplots.AxesSubplot at 0x23c1711e608>
```

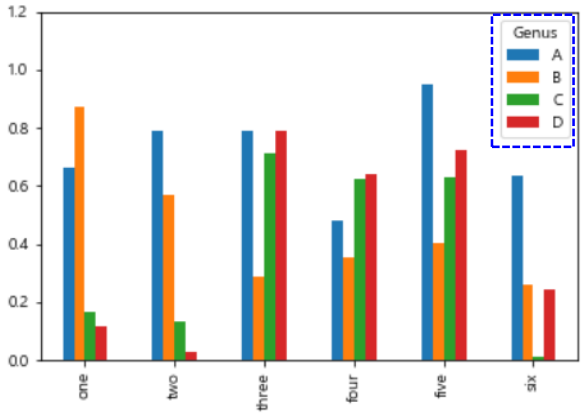

누적 가로 막대

- **옵션 stacked=True**

```
In [155]: df = pd.DataFrame(np.random.rand(6, 4),
                            index=['one', 'two', 'three', 'four', 'five', 'six'],
                            columns=pd.Index(['A', 'B', 'C', 'D'], name='Genus'))
          df
```

Out[155]:

Genus	A	B	C	D
one	0.664737	0.872716	0.167458	0.114329
two	0.789941	0.569340	0.135387	0.029364
three	0.790764	0.285031	0.714794	0.790372
four	0.481273	0.356014	0.622913	0.641138
five	0.951389	0.405259	0.632018	0.724206
six	0.632867	0.259472	0.012550	0.240667

```
In [162]: df.plot.barh(stacked=True, alpha=0.5)
```

```
Out[162]: <matplotlib.axes._subplots.AxesSubplot at 0x23c14c65b08>
```

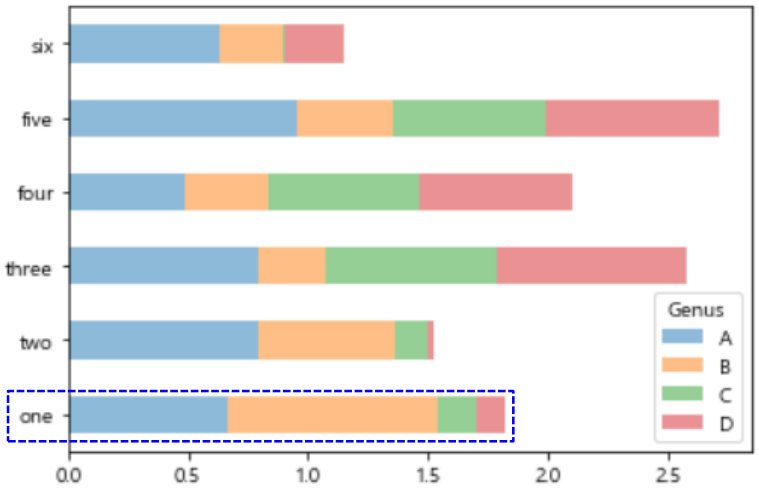

요일별 식당 인원 수 규모

- **각 행의 합이 1이 되도록 정규화**
  - 요일별 식당 방문객 인원 수 비율

In [4]:
```
tips = pd.read_csv('examples/tips.csv')
tips.head()
```

Out[4]:

	total_bill	tip	smoker	day	time	size
0	16.99	1.01	No	Sun	Dinner	2
1	10.34	1.66	No	Sun	Dinner	3
2	21.01	3.50	No	Sun	Dinner	3
3	23.68	3.31	No	Sun	Dinner	2
4	24.59	3.61	No	Sun	Dinner	4

In [6]:
```
party_counts = pd.crosstab(tips['day'], tips['size'])
party_counts.head()
```

Out[6]:

size	1	2	3	4	5	6
day						
Fri	1	16	1	1	0	0
Sat	2	53	18	13	1	0
Sun	0	39	15	18	3	1
Thur	1	48	4	5	1	3

In [8]:
```
# Normalize to sum to 1
party_pcts = party_counts.div(party_counts.sum(1), axis=0)
party_pcts.head()
```

Out[8]:

size	1	2	3	4	5	6
day						
Fri	0.052632	0.842105	0.052632	0.052632	0.000000	0.000000
Sat	0.022989	0.609195	0.206897	0.149425	0.011494	0.000000
Sun	0.000000	0.513158	0.197368	0.236842	0.039474	0.013158
Thur	0.016129	0.774194	0.064516	0.080645	0.016129	0.048387

In [7]:
```
party_pcts.plot.bar()
```

Out[7]:
```
<matplotlib.axes._subplots.AxesSubplot at 0x2cf8d3f7c88>
```